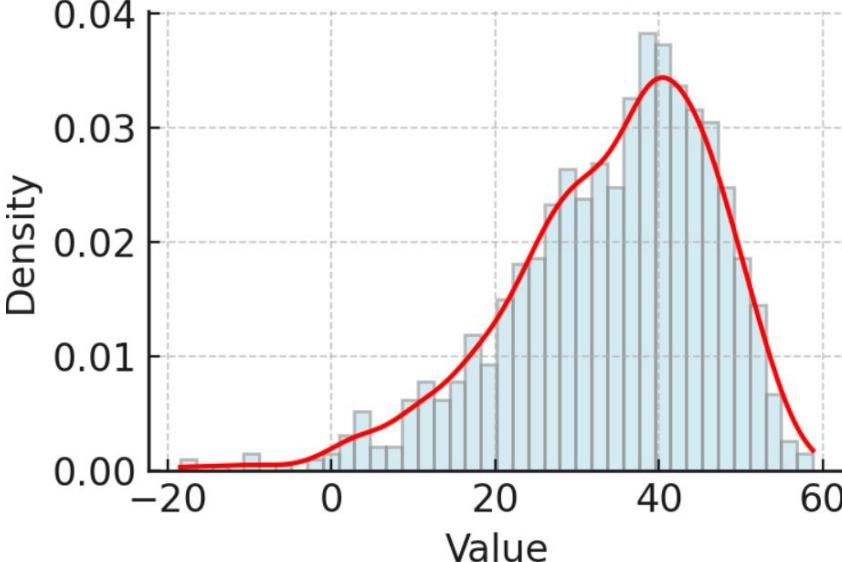


# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
D	<p>1. 若某數據點的 Z 分數 (Z-Score) = 2，請問代表下列哪一種意涵？</p> <p>(A)代表該數據點之原始數值為 2； (B)該數據點比平均值低 2 個標準差； (C)代表數據為異常值； (D)該數據點比平均值高 2 個標準差</p>
B	<p>2. 使用 Python 的 pandas 套件處理各商品銷售數據（變數為 df）時，若需計算「總銷售額」欄位的敘述性統計量（如平均值、標準差等），應使用下列哪一種語法？</p> <p>(A)df['總銷售額'].sum(); (B)df['總銷售額'].describe(); (C)df['總銷售額'].sort_values(); (D)df['總銷售額'].stats()</p>
A	<p>3. 附圖為某資料之分佈圖，此圖資料之偏態 (Skewness) 值較有可能為下列哪個選項？</p>  <p>(A)Skewness &lt; 0; (B)Skewness &gt; 0; (C)Skewness = 0; (D)無法計算 Skewness</p>
B	<p>4. 累積分佈函數 (Cumulative Distribution Function, CDF) 可用於描述隨機變數的機率分佈特性，其數學定義為下列何者？</p> <p>(A)機率密度函數 (Probability Density Function, PDF) 的平均值； (B)機率密度函數 (Probability Density Function, PDF) 的積分；</p>

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	(C)機率密度函數 (Probability Density Function, PDF) 的離散總和； (D)機率密度函數 (Probability Density Function, PDF) 的標準差
B	5. 在進行資料前處理時，若使用 Label Encoding 將類別變數轉換為數字型態，下列何者為最常見的潛在風險？ (A)無法處理缺值； (B)會引入類別之間的虛假順序關係； (C)無法擴展至新資料； (D)記憶體佔用過高
C	6. 在進行資料分析時，會遇到類別型 (Categorical) 與數值型 (Numerical) 資料格式。關於這兩種資料格式的處理，下列敘述何者不正確？ (A)One-Hot 編碼 (One-Hot Encoding) 會將類別變數轉換為多維二元向量，適用於無序 (Nominal) 類別資料，但在高基數 (High Cardinality) 特徵下可能造成維度爆炸問題； (B)標籤編碼 (Label Encoding) 會以整數表示不同類別，若應用於無序 (Nominal) 資料，可能導致模型誤將編碼值解讀為具數值大小關係的特徵； (C)標準化 (Standardization) 透過將資料平移與縮放，使其平均值為 0、標準差為 1，可在多數距離型演算法中改善收斂速度，並同時將數值範圍壓縮至 0 至 1 之間； (D)對連續變數進行分箱 (Binning) 可提升模型可解釋性，但若分段方式未依據資料分佈特性設計，可能導致資訊損失或邊界偏誤
C	7. 在資料庫的 ACID 特性中，下列何者為「原子性 (Atomicity)」的正確定義？ (A)所有資料欄位必須為相同型別； (B)每次交易需以批次方式執行； (C)交易不可分割，需完全成功或完全失敗； (D)系統會自動同步交易資料至所有節點
B	8. 資料科學家為分析顧客行為，利用現有欄位「銷售金額」與「瀏覽次數」，計算出新變數「銷售金額/瀏覽次數」。此動作屬於下列哪一類特徵工程方法？ (A)特徵選擇 (Feature Selection)； (B)特徵衍生 (Feature Derivation)；

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	(C)特徵轉換 (Feature Transformation); (D)分箱處理 (Binning)
C	9. 在進行數值特徵的標準化 (Normalization) 時，若資料中存在極端值 (Outliers)，下列哪一種方法最適合使用？ (A)Min-Max 正規化 (Min-Max Scaling); (B)Z-score 標準化 (Z-score Normalization); (C)穩健縮放 (Robust Scaling); (D)標準分箱 (Standard Binning)
C	10 下列哪一種情境最適合應用異常偵測 (Anomaly Detection) 技術？ (A)根據歷史銷售資料預測特定商品在旺季期間是否會出現供貨短缺，以提前調整庫存策略； (B)透過信用風險模型預測顧客是否可能發生違約，以輔助核貸決策； (C)即時分析金融交易資料流，偵測與平常交易行為明顯不同的可疑交易紀錄； (D)監控線上服務平台的使用者登入次數，預測次日的登入量變化趨勢
C	11 若一家公司需即時監控大量物聯網裝置的異常行為，下列哪一種組合最適合此應用？ (A)傳統關聯式資料庫+圖形視覺化； (B)批次資料處理+雲端備份； (C)大數據平台+即時資料分析技術； (D)Word 文件+手動標註
A	12 在處理分類問題時，若某一類樣本數明顯少於其他類別，研究人員可能採用隨機過採樣 (Random Oversampling) 以平衡資料比例，此方法最常造成下列哪一種問題？ (A)增加過擬合風險； (B)降低模型的收斂速度； (C)減少資料總筆數數量； (D)導致訓練資料欄位缺失
D	13 下列何者為同態加密 (Homomorphic Encryption) 技術的核心特性？ (A)將資料轉換為匿名識別碼以隱藏身分； (B)對資料進行標準化處理以提升模型精度； (C)自動偵測與排除異常值； (D)可直接在加密狀態下進行數據運算

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
D	<p>14 某組資料共 10 項標籤如下： A, A, A, A, A, B, B, B, B, B 若該標籤僅有 A、B 兩種，請問這組資料的「正規化吉尼不純度 (Normalized Gini impurity)」為何？</p> <p>(A)0； (B)0.42； (C)0.84； (D)1</p>
C	<p>15 某家客服中心統計資料發現，平均每小時會接到約 20 通顧客來電，但每分鐘的來電數量不固定，可能為 0、1、2 通不等。這些來電事件彼此獨立，且在短時間內，發生的機率與時間長短成正比。若要以機率模型描述「每分鐘接到幾通來電」的機率分佈，下列哪一種最適合使用？</p> <p>(A)均勻分佈 (Uniform distribution)； (B)指數分佈 (Exponential distribution)； (C)卜瓦松分佈 (Poisson distribution)； (D)常態分佈 (Normal distribution)</p>
A	<p>16 某金融科技公司以 Z 分數 (Z-Score) 監控交易金額異常狀況。若交易金額平均為新台幣 2,000 元，標準差為 400 元，某筆交易金額為 3,200 元，且公司以 <math> Z  \geq 3</math> 判定為異常值 (Outlier)，下列判斷何者最為正確？</p> <p>(A)該筆交易的 Z 分數為 3，應標記為異常值； (B)該筆交易的 Z 分數為 2.5，屬於合理變異範圍； (C)該筆交易的 Z 分數為 2，顯示模型標準差估計過高； (D)該筆交易的 Z 分數為 1.5，無須納入異常檢測</p>
B	<p>17 某電商公司欲利用顧客行為資料建立消費預測模型，其中「會員等級」欄位包含「一般、白金、黑卡」三種類別。若模型採用梯度提升樹 (Gradient Boosting Tree) 演算法，資料科學家在進行特徵編碼時應特別注意下列何種情況？</p> <p>(A)應優先採用獨熱編碼 (One-Hot Encoding)，以減少類別之間的相依性與記憶體使用量； (B)直接使用標籤編碼 (Label Encoding) 可能使模型誤判類別間存在順序關係，導致特徵重要性偏誤； (C)使用目標編碼 (Target Encoding) 會自動消除過擬合</p>

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	(Overfitting) 風險； (D)若類別數量較少，建議先使用主成分分析 (Principal Component Analysis, PCA) 進行降維
A	18 某人工智慧團隊使用分散式資料庫 (Distributed Database) 儲存模型訓練資料，並在更新訓練樣本時啟用多節點交易。若其中一個節點在交易過程中發生錯誤，但系統仍確保整體資料不會出現部分更新、最終狀態維持一致，下列何者最能說明此現象？ (A)系統透過原子性 (Atomicity) 確保交易必須全部成功或全部回復 (Rollback)； (B)系統透過一致性 (Consistency) 確保交易完成後資料符合完整性規則； (C)系統透過隔離性 (Isolation) 避免多筆交易同時存取或修改相同資料； (D)系統透過持久性 (Durability) 確保交易一旦提交，其結果將永久保留於資料庫中
C	19 某製造企業導入上萬台物聯網 (IoT) 感測器以進行設備健康監測。系統需在毫秒級回應異常事件，並同時將完整資料保留於雲端供後續 AI 模型訓練與分析。若企業希望兼顧即時性、資料完整性與可擴展性，下列哪一種資料流程設計最符合此目標？ (A)感測器 → 雲端 API Gateway → 分散式資料庫→ 批次特徵工程 (→ 模型推論)； (B)感測器 → MQTT Broker → 雲端資料倉儲→ 即時儀表板→ 模型再訓練； (C)感測器 → 邊緣運算節點→ 流式資料處理框架 (Stream Processing Framework) → 雲端資料湖→ 模型推論； (D)感測器 → 本地快取層→ RESTful API → 雲端報表系統) → 模型批次更新
D	20 某銀行計畫將信用風險評估模型部署至雲端平台，以便即時分析客戶交易行為。由於涉及大量敏感金融資料，銀行要求雲端服務商在不解密原始資料的情況下仍能執行模型運算。為達成此目標，最適合採用下列哪一項技術？ (A)在上傳資料前進行匿名化 (Anonymization)，僅保留可識別代碼供比對使用；

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	(B)利用雜湊 (Hash) 函數轉換資料，以確保模型可追蹤但無法還原個資； (C)採用資料本地化 (Data Localization) 策略，將所有模型訓練限制於內部伺服器中； (D)透過同態加密 (Homomorphic Encryption)，讓雲端系統能直接在加密資料上執行運算，解密後結果與原始資料一致
B	21 某資料分析師設計在業務績效報告時，希望單一頁面中同時呈現多區域、不同產品線的銷售趨勢變化，並確保主管能在短時間內掌握整體資料走向。若依據 Edward Rolf Tufte 的數據密度 (Data Density) 原則，下列哪一種設計方式最能符合該概念？ (A)將每個區域的銷售資料分成多張獨立折線圖，以避免資訊重疊； (B)使用顏色區分產品線，於同一圖表中整合多區域趨勢線，保持比例一致且標註清晰； (C)移除所有輔助線與標籤，僅保留主要折線以凸顯趨勢； (D)將資料轉換為表格形式，確保數值精確呈現並取代圖表視覺化
D	22 某投資研究員希望分析四檔科技類股 (A、B、C、D) 每日報酬率的變化趨勢，以判斷這些股票之間是否存在高度相關性與共變動性，並評估投資組合分散風險的程度。若研究員希望以單一圖表快速呈現各股票間的關聯強度與方向，下列哪一種視覺化呈現方式最適合？ (A)為每檔股票各自繪製直方圖 (Histogram) 以比較報酬率分佈； (B)針對任兩檔股票繪製散佈圖並加上趨勢線 (Regression Line)； (C)使用雙軸折線圖 (Dual-axis Line Chart) 同時顯示四檔股價變化； (D)熱力圖 (Heatmap) 配合相關係數矩陣 (Correlation Matrix)
C	23 某研究團隊以單樣本 t 檢定 (one-sample t-test) 檢驗「新行銷策略後的平均月銷售額是否與原本的 100 萬元不同」，顯著水準設定為 $\alpha = 0.05$ 。檢定結果顯示： $p$ 值 = 0.08，且 95% 信賴區間為 [95 萬元, 108 萬元]。根據上述結果，下列敘述何者正確？ (A)因 $p$ 值 < 0.05，可拒絕虛無假設； (B)若顯著水準改為 0.10，仍不顯著； (C)因 100 萬元落在信賴區間內，無法拒絕虛無假設； (D)信賴區間寬度僅與顯著水準有關
A	24 某企業建置生成式 AI 系統，利用大量客服紀錄與產品評論資料訓練語言模型，以自動生成客服回覆與知識摘要。由於資料來源多樣，且包含非結構化資料，下列哪一項不是該系統可能遇到的挑戰？ (A)資料品質不一，導致模型訓練效能低落； (B)資料量龐大，導致模型訓練時間過長； (C)資料內容複雜，導致模型無法準確理解； (D)資料格式多樣，導致模型無法直接使用

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	<p>構化文字、影像與表格資訊，團隊希望在不降低模型效能的前提下，提升資料處理效率與一致性，下列哪一種資料處理策略最適合？</p> <p>(A)建立資料湖（Data Lake）結構，並以 Apache Spark 或 Ray 進行分散式資料預處理與特徵抽取，再串接至模型訓練管線（Pipeline）；</p> <p>(B)採用單節點高效能伺服器搭配批次處理模式，集中執行資料清理與格式轉換；</p> <p>(C)將所有文字資料轉換為向量，並以資料庫索引方式直接餵入語言模型訓練；</p> <p>(D)使用生成式模型先行自動清理資料內容，再將結果輸入至下游訓練流程</p>
A	25 某電商資料團隊繪製顧客單筆消費金額的箱型圖後發現：四分位距（IQR）範圍極小，但上鬚線拉得很長，且在高金額區域有多筆離群值。若希望協助行銷部門依據消費層級設計分群策略，下列哪一種視覺化方式最有助於凸顯不同消費層級間的差異？ <p>(A)以對數刻度繪製箱型圖或長條圖，放大高金額消費族群的變化差異；</p> <p>(B)移除所有離群值，確保資料呈現集中分布；</p> <p>(C)採用等距分箱（Equal-Width Binning）方式分群；</p> <p>(D)改以折線圖（Line Chart）觀察時間變化趨勢</p>
C	26 某串流影音平台運用關聯規則學習（Association Rule Learning）分析用戶的觀影行為，發現若使用者觀看了科幻影集，則有較高機率接著觀看超級英雄電影。分析顯示，同時觀看這兩種類型的使用者約佔全部觀影紀錄的 12%，而觀看科幻影集的使用者中，有 50%也觀看了超級英雄電影，該規則的提升度（Lift）為 1.8。根據上述資訊，下列哪一項推論最為正確？ <p>(A)支持度（Support）過低，代表此規則不具任何商業價值；</p> <p>(B)提升度（Lift）大於 1 表示兩種類型內容無關，僅屬於隨機重疊；</p> <p>(C)信賴度（Confidence）為 50%，代表觀看科幻影集者有明顯傾向觀看超級英雄電影；</p> <p>(D)同時觀看比例僅 12%，代表兩種類型互相排斥</p>
D	27 某金融科技公司分析每日上億筆交易資料，以監控客戶轉帳金額分佈與異常波動。由於資料量極大，為兼顧效率與準確度，團隊決定採用「近似分位數（Approximate Quantile）」方法進行資料摘要統計。下列何者最能正確反映該技術的核心目的？

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	(A)確保每個分位值的結果完全精確，即使計算時間較長； (B)利用機器學習模型預測分位數位置，以減少統計計算量； (C)僅能對結構化資料進行批次處理，無法應用於即時資料流； (D)在可容忍誤差範圍內，快速估算分位值以支援即時分析
A	28 若在高維度 ( $>500$ 維) 的資料上應用 DBSCAN (Density-Based Spatial Clustering of Applications with Noise) 演算法，卻發現所有資料點皆被判定為雜訊 (Noise)，下列何者為最有可能的原因？ (A)高維下距離變化趨同，導致 $\epsilon$ (Epsilon) 閾值選擇失效； (B)使用錯誤的距離函數 (Distance Function)； (C)MinPts 參數設得太小； (D)資料過度標準化導致特徵消失
D	29 某團隊在開發風險評估模型時，使用主成分分析 (Principal Component Analysis, PCA) 進行降維。輸入資料包含三個數值欄位：「交易金額（單位：新台幣）」、「交易次數（次／月）」與「年齡（歲）」，其數值量級分別約為 $10^5$ 、 $10^1$ 與 $10^2$ 。分析人員直接將原始數據帶入 PCA，結果第一主成分 (PC1) 幾乎完全由「交易金額」主導。下列哪一項作法或判斷最合理？ (A)這是正常現象，金額本身變異較大，應主導主要成分； (B)若改用特徵選擇法，可自動解決變數量級問題； (C)可刪除「交易金額」欄位以平衡各主成分的影響； (D)在進行 PCA 前應先進行標準化 (Standardization)，以避免因數值尺度差異造成特徵偏誤
C	30 某行銷團隊想了解「廣告預算」與「銷售金額」之間的關聯程度。經繪製散佈圖後發現兩者呈現明顯線性趨勢，且資料中無明顯離群值 (Outliers)。若希望衡量兩者之間線性關係的強度與方向，下列哪一種方法最適合？ (A)均方根誤差 (Root Mean Squared Error, RMSE)； (B)共變異數 (Covariance)； (C)皮爾森相關係數 (Pearson Correlation Coefficient)； (D)平均絕對誤差 (Mean Absolute Error, MAE)
B	31 某電商團隊觀察到，每位顧客對廣告推播的點擊行為可視為一次伯努利試驗 (Bernoulli Trial)，單次點擊成功機率為 $p=0.4$ 。當推播對象擴增至 5,000 位顧客時，團隊想快速預估「成功點擊總數」的分佈情形，以進行

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	<p>模型效能模擬與預測。若希望以常態分佈 (Normal Distribution) 近似原始分佈，下列哪一項判斷最為合理？</p> <p>(A)因樣本數極大，可直接以常態分佈近似二項分佈 (Binomial Distribution)；</p> <p>(B)只有當 <math>np</math> 與 <math>n(1-p)</math> 皆大於 5 時，才能以常態分佈作近似；</p> <p>(C)常態近似只適用於 <math>p=0.5</math> 的情況；</p> <p>(D)無論樣本數多大，二項分佈都不能以常態分佈近似</p>
A	32 某電信公司導入生成式 AI 客服系統，利用過去對話紀錄與用戶行為資料訓練語言模型，在資料治理與合規審查過程中，團隊發現模型可能會在回答中生成包含真實姓名、電話或交易資訊的內容。為確保系統符合個資法及生成式 AI 的安全與隱私要求，下列哪一項作法最符合實務可行及法規原則？
	<p>(A)在訓練資料前進行資料匿名化 (Anonymization) 或偽匿名化 (Pseudonymization) 處理，並建立輸出內容稽核機制；</p> <p>(B)改以強化學習 (Reinforcement Learning) 微調模型，使模型學習避免產出真實資訊；</p> <p>(C)採用同態加密 (Homomorphic Encryption) 以加密所有文字輸入，確保模型無法辨識任何個資；</p> <p>(D)僅設定模型回覆時不顯示用戶姓名，即可視為隱私防護完成</p>
D	33 某金融機構的量化分析師在建立資產風險評估模型時，發現報酬率資料分佈明顯非對稱，且出現多次極端損失事件，使得傳統假設常態分佈的模型無法準確反映真實風險。若希望在不依賴常態分佈假設的前提下，採取更能捕捉資料極端情況的建模策略，下列哪一種方法最為合適？
	<p>(A)採用線性迴歸模型 (Linear Regression Model)，以常態分佈殘差 (Residuals) 為基礎進行推估；</p> <p>(B)使用平均數 (Mean) 與標準差 (Standard Deviation) 估計波動範圍；</p> <p>(C)將資料裁剪至 <math>\pm 3\sigma</math> 範圍內以排除異常值影響；</p> <p>(D)採用分位數回歸模型 (Quantile Regression Model)，聚焦於尾部分位 (Tail Quantiles) 以評估極端風險</p>
B	34 在圖形資料庫 (Graph Database) 中建模社群平台資料時，若每筆「按讚」行為都包含時間戳記 (Timestamp) 與裝置類型 (Device Type) 等資訊。若希望同時保留使用者與貼文之間的互動關係，並能有效查詢「按

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	<p>「讚」的行為屬性，下列哪一種設計方式最為合適？</p> <p>(A)將「按讚」視為節點（Node），與使用者建立邊（Edge）；</p> <p>(B)將「按讚」資訊作為邊的屬性（Property）儲存，連結使用者與被按讚的貼文節點；</p> <p>(C)把「按讚」資訊直接寫入使用者節點中作為屬性；</p> <p>(D)建立「按讚紀錄表」並將資料存入關聯式資料庫</p>
B	<p>35 某企業欲建構知識圖譜（Knowledge Graph），以整合內部的研究報告、專利資料與專家知識，並支援語意查詢與關聯推理。若希望模型能具備良好的語意擴展性與高效推理能力，下列哪一種圖模型設計最為合適？</p> <p>(A)僅以節點（Node）與邊（Edge）表示，所有資訊存放於節點屬性中；</p> <p>(B)將資料結構建為 RDF（Resource Description Framework）三元組（Subject - Predicate - Object）；</p> <p>(C)使用文件型資料庫儲存內容，並以標籤（Tag）連接節點；</p> <p>(D)採用關聯式資料庫儲存對應關係，並搭配預建索引加速查詢</p>
B	<p>36 某研究人員欲使用線性迴歸模型（Linear Regression Model）分析變數 Y 與 X 之間的關係，但發現 Y 的分佈明顯右偏，且其變異數隨 X 的增大而增加。為滿足模型假設並提升配適效果，下列哪一種前處理方法最為合適？</p> <p>(A)對 X 進行標準化（Standardization）；</p> <p>(B)對 Y 進行 Box - Cox 轉換（Box - Cox Transformation）；</p> <p>(C)對資料進行一次差分（First Differencing）；</p> <p>(D)將 Y 中變異較大的樣本移除</p>
C	<p>37 若開發一個用於罕見疾病自動診斷的分類模型，目前資料集中確診樣本僅佔不到 1%，且因為標註成本高，短期內無法取得更多資料。在此情況下，若希望提升模型對少數類的偵測能力，同時避免過擬合，下列哪一種策略最為合理？</p> <p>(A)對少數類進行隨機過採樣（Random Oversampling）；</p> <p>(B)對多數類進行欠採樣（Random Undersampling）；</p> <p>(C)使用 SMOTE（Synthetic Minority Over-sampling Technique）生成合成少數類樣本後再訓練分類模型；</p> <p>(D)僅使用現有資料調整模型決策閾值（Decision Threshold）以提升召回率</p>
B	38 一家製造廠評估新生產線推出後，產品良率是否較原生產線提升。工程師

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	<p>分別從兩條生產線各抽樣 100 件產品，原生產線良率為 95%，新生產線為 97%。若欲檢定兩條生產線良率的差異是否具有統計意義，下列哪一種方法最為合適？</p> <p>(A)雙樣本平均數 t 檢定 (Two-sample t-test); (B)雙比例 Z 檢定 (Two-proportion Z-test); (C)卡方檢定 (Chi-square test); (D)變異數分析 (ANOVA)</p>
D	<p>39 若評估一個新開發的腫瘤分類模型，其資料集中有 80%的樣本來自良性病例。若直接使用 5-fold 交叉驗證 (Cross-Validation) 進行模型評估，可能導致模型效能評估出現偏差，為避免此問題，下列哪一種作法最合適？</p> <p>(A)降低 K 值以減少交叉驗證次數； (B)改為使用拔靴法 (Bootstrap); (C)調整測試集使良性樣本比例更高，以模擬真實分佈； (D)使用分層交叉驗證 (Stratified K-Fold Cross-Validation)，以確保每折類別比例一致</p>
B	<p>40 請參考附圖，下列虛擬程式碼 (pseudocode) 最可能是在描述何種驗證法？</p> <p><b>Input :</b></p> <ul style="list-style-type: none"><li>- <code>data_set</code> : 包含 <code>N</code> 筆資料的資料集</li><li>- <code>model_training_function</code> : 用來訓練模型的函式</li><li>- <code>model_evaluation_function</code> : 用來評估模型的函式 (如計算誤差或準確率)</li></ul> <p><b>Output :</b></p> <ul style="list-style-type: none"><li>- 平均評估指標 (如平均準確率或平均誤差)</li></ul> <p><b>Algorithm :</b></p> <ol style="list-style-type: none"><li>1. 初始化評估指標列表 <code>metrics = []</code></li><li>2. 對 <code>i = 1</code> 到 <code>N</code>：<ol style="list-style-type: none"><li>a. 將第 <code>i</code> 筆資料作為測試集 <code>test_data</code></li><li>b. 將其餘 <code>N-1</code> 筆資料作為訓練集 <code>train_data</code></li><li>c. 使用 <code>model_training_function</code> 在 <code>train_data</code> 上訓練模型</li><li>d. 使用訓練好的模型對 <code>test_data</code> 做預測，計算評估指標 <code>metric_i</code></li><li>e. 將 <code>metric_i</code> 加入 <code>metrics</code></li></ol></li><li>3. 計算 <code>metrics</code> 的平均值 <code>mean_metric</code></li><li>4. 回傳 <code>mean_metric</code></li></ol> <p>(A) Hold-out 驗證 (Hold-out Validation)；</p>

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	(B)留一交叉驗證 LOOCV (Leave-One-Out Cross Validation); (C) K-fold 交叉驗證 (K-fold Cross Validation); (D)拔靴法 (Bootstrap) 驗證
A	41 請參考附圖，下列虛擬程式碼 (pseudocode) 最可能是在描述何種演算法？  <b>Input :</b> <ul style="list-style-type: none"><li>- <code>data_points</code> : N 筆資料，每筆資料有 D 個特徵</li><li>- <code>x</code> : 要分成的群數</li></ul> <b>Output :</b> <ul style="list-style-type: none"><li>- <code>clusters</code> : 每筆資料所屬的群編號</li><li>- <code>centroids</code> : 每個群的中心點</li></ul> <b>Algorithm :</b> <ol style="list-style-type: none"><li>1. 隨機選擇 <code>x</code> 個資料點作為初始中心</li><li>2. 重複以下步驟直到收斂：<ol style="list-style-type: none"><li>a. 分群：             對每個資料點，計算它到每個中心的距離             將資料點指派給距離最近的中心</li><li>b. 更新中心：             對每個群：                 計算該群中所有資料點的平均值                 將群中心更新為這個平均值</li></ol></li><li>3. 當群中心不再變動時，停止</li></ol> 回傳每筆資料的群編號 <code>clusters</code> ，以及最後的群中心 <code>centroids</code> (A)K-means 分群 (K-means Clustering); (B)高斯混合模型分群 (Gaussian Mixture Model Clustering); (C)階層式分群 (Hierarchical Clustering); (D)DBSCAN 分群 (Density-based Spatial Clustering of Applications with Noise Clustering)
C	42 考慮某生產線每小時出現瑕疵品的個數符合卜瓦松分佈 (Poisson Distribution)，已知平均每小時產生 5 個瑕疵品，附圖程式碼展示資料處理，請問下列敘述何者正確？

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目																																																																							
	<pre>import numpy as np from scipy.stats import poisson lambda_poisson = 5 print(poisson.pmf(5, lambda_poisson))</pre> <p>(A) <code>lambda_poisson = 5</code> 表示每小時最多 5 個瑕疵品； (B) <code>poisson.pmf(5, lambda_poisson)</code> 表示小於 5 個瑕疵品的機率； (C) 卜瓦松分佈的適用條件為事件彼此獨立，且平均發生率固定； (D) <code>poisson.cdf(10, 5)</code> 表示大於或等於 10 個瑕疵品的機率</p>																																																																							
	<p>一間遊戲市場研究公司正在分析全球電子遊戲銷售情況，並準備建立一份「熱銷遊戲銷售報告」。分析師取得了一份名為 <code>vgsales.csv</code> 的資料集，內容包含了全球銷量超過 10 萬份的電子遊戲清單。研究團隊希望透過這份資料，了解不同年份、平台與地區的銷售趨勢。資料集的欄位說明如下，請根據下述資料情境回答以 43~47 題。</p> <p>Name：遊戲名稱 Platform：遊戲平台（如 PS4、X360、Wii 等） Year：發售年份 Genre：遊戲類型（如 Action、Sports、Role-Playing 等） Publisher：發行商名稱 NA_Sales / EU_Sales / JP_Sales / Other_Sales：各地區銷售量（單位：百萬份） Global_Sales：全球總銷售量（單位：百萬份）</p> <p>資料的欄位概觀如下：</p> <pre>import pandas as pd import matplotlib.pyplot as plt import seaborn as sns  # 載入資料 data = pd.read_csv("vgsales.csv") data.head()</pre> <table border="1"><thead><tr><th>Rank</th><th>Name</th><th>Platform</th><th>Year</th><th>Genre</th><th>Publisher</th><th>NA_Sales</th><th>EU_Sales</th><th>JP_Sales</th><th>Other_Sales</th><th>Global_Sales</th></tr></thead><tbody><tr><td>0</td><td>1</td><td>Wii Sports</td><td>Wii</td><td>2006.0</td><td>Sports</td><td>Nintendo</td><td>41.49</td><td>29.02</td><td>3.77</td><td>8.46</td><td>82.74</td></tr><tr><td>1</td><td>2</td><td>Super Mario Bros.</td><td>NES</td><td>1985.0</td><td>Platform</td><td>Nintendo</td><td>29.08</td><td>3.58</td><td>6.81</td><td>0.77</td><td>40.24</td></tr><tr><td>2</td><td>3</td><td>Mario Kart Wii</td><td>Wii</td><td>2008.0</td><td>Racing</td><td>Nintendo</td><td>15.85</td><td>12.88</td><td>3.79</td><td>3.31</td><td>35.82</td></tr><tr><td>3</td><td>4</td><td>Wii Sports Resort</td><td>Wii</td><td>2009.0</td><td>Sports</td><td>Nintendo</td><td>15.75</td><td>11.01</td><td>3.28</td><td>2.96</td><td>33.00</td></tr><tr><td>4</td><td>5</td><td>Pokemon Red/Pokemon Blue</td><td>GB</td><td>1996.0</td><td>Role-Playing</td><td>Nintendo</td><td>11.27</td><td>8.89</td><td>10.22</td><td>1.00</td><td>31.37</td></tr></tbody></table>	Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sales	JP_Sales	Other_Sales	Global_Sales	0	1	Wii Sports	Wii	2006.0	Sports	Nintendo	41.49	29.02	3.77	8.46	82.74	1	2	Super Mario Bros.	NES	1985.0	Platform	Nintendo	29.08	3.58	6.81	0.77	40.24	2	3	Mario Kart Wii	Wii	2008.0	Racing	Nintendo	15.85	12.88	3.79	3.31	35.82	3	4	Wii Sports Resort	Wii	2009.0	Sports	Nintendo	15.75	11.01	3.28	2.96	33.00	4	5	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	Nintendo	11.27	8.89	10.22	1.00	31.37
Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sales	JP_Sales	Other_Sales	Global_Sales																																																														
0	1	Wii Sports	Wii	2006.0	Sports	Nintendo	41.49	29.02	3.77	8.46	82.74																																																													
1	2	Super Mario Bros.	NES	1985.0	Platform	Nintendo	29.08	3.58	6.81	0.77	40.24																																																													
2	3	Mario Kart Wii	Wii	2008.0	Racing	Nintendo	15.85	12.88	3.79	3.31	35.82																																																													
3	4	Wii Sports Resort	Wii	2009.0	Sports	Nintendo	15.75	11.01	3.28	2.96	33.00																																																													
4	5	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	Nintendo	11.27	8.89	10.22	1.00	31.37																																																													

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
B	<p>43</p> <pre>data['Year']</pre> <p>0      2006.0 1      1985.0 2      2008.0 3      2009.0 4      1996.0       ... 16593    2002.0 16594    2003.0 16595    2008.0 16596    2010.0 16597    2003.0 Name: Year, Length: 16598, dtype: float64</p> <p>分析師在載入資料後，檢視 Year 欄位的資料型態，發現它是 float64，而非一般年份常用的整數。他想了解這樣的情形為什麼會發生。請問下列哪些原因可能導致這種狀況？</p> <p>原因 A：CSV 檔中 Year 欄位有缺失值(NaN)，導致 Pandas 自動將整欄轉為浮點數。</p> <p>原因 B：CSV 檔中的年份資料原本是字串(如 "2006")，Pandas 轉換時出錯而變成浮點數。</p> <p>原因 C：Pandas 預設會將所有數值型態讀取為 float64，不論資料是否為整數。</p> <p>原因 D：CSV 檔中的年份資料可能包含小數點(例如 2006.0)，因此被視為浮點數。</p> <p>(A)原因 B、原因 C； (B)原因 A、原因 D； (C)原因 A、原因 B、原因 D； (D)原因 C、原因 D</p>
D	<p>44 研究團隊接下來想要將 Year 欄位轉換為整數型態，以便後續進行年份趨勢分析。考慮到資料中可能包含缺失值 (NaN)，請選出最合適的轉換方式。</p> <p>(A)data['Year'] = data['Year'].astype(int); (B)data['Year'] = data['Year'].fillna(0).astype(int); (C)data['Year'] = data['Year'].fillna(1).astype(int); (D)data['Year'] = data['Year'].astype('Int64');</p>
A	<p>45 為了觀察各遊戲平台的市場表現，分析師想要統計每個平台的全球銷售總額，並以長條圖呈現。請選出最能正確實現此分析的程式碼。</p> <p>(A)data.groupby("Platform")["Global_Sales"].sum().plot(kind="bar"); (B)data.groupby("Platform")["Global_Sales"].count().plot(kind="bar");</p>

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	(C)data["Platform"].value_counts().plot(kind="bar"); (D)data.groupby("Platform")["Global_Sales"].mean().plot(kind="bar")
C	46 團隊希望比較北美、歐洲、日本及其他地區的整體銷售比例，並使用 seaborn 套件以長條圖的形式進行可視化分析。請選出能正確顯示這些地區銷售總額比例的程式碼。 (A)sns.countplot(x=["NA_Sales", "EU_Sales", "JP_Sales", "Other_Sales"], data=data); (B)sns.lineplot(x="Platform", y=["NA_Sales", "EU_Sales", "JP_Sales", "Other_Sales"], data=data); (C)sns.barplot(x="variable", y="value", data=pd.melt(data, value_vars=["NA_Sales", "EU_Sales", "JP_Sales", "Other_Sales"]), estimator=sum); (D)sns.histplot(data[["NA_Sales", "EU_Sales", "JP_Sales", "Other_Sales"]])
B	47 研究團隊想要知道在北美地區（NA）銷售成績最好的遊戲前五名，並希望以 seaborn 的條狀圖呈現結果。請選出能正確完成這項分析的程式碼。 (A)sns.barplot(x="NA_Sales", y="Name", data=data.head(5)); (B)sns.barplot(x="Name", y="NA_Sales", data=data.nlargest(5, "NA_Sales")); (C)sns.lineplot(x="Name", y="NA_Sales", data=data.nlargest(5, "NA_Sales")); (D)sns.countplot(x="Name", y="NA_Sales", data=data)
	使用銷售資料集(marketing.csv)進行迴歸分析，附圖程式碼展示資料載入與處理，請回答後續 48~50 題。 <pre>import pandas as pd df = pd.read_csv("marketing.csv")</pre> <p>下圖顯示資料集的前 5 筆資料與相關資訊。</p>

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	<pre>&gt;&gt;&gt; df.head()    youtube  facebook  newspaper  sales 0    276.12      45.36     83.04  26.52 1     53.40        Nan      54.12  12.48 2    20.64       55.08     83.16  11.16 3   181.80       49.56     70.20  22.20 4   216.96       12.96     70.08  15.48 &gt;&gt;&gt; df.describe()             youtube      facebook      newspaper        sales count    200.000000  199.000000  200.000000  200.000000 mean    176.451000  27.820101  36.664800  16.827000 std     103.025084  17.808410  26.134345  6.260948 min      0.840000  0.000000  0.360000  1.920000 25%     89.250000  11.940000  15.300000  12.450000 50%    179.700000  27.000000  30.900000  15.480000 75%    262.590000  43.680000  54.120000  20.880000 max    355.680000  59.520000 136.800000  32.400000</pre>
D	48 根據上述結果，下列何者正確？ (A)資料集個數為 199 筆，變數個數為 4 個； (B)sales 變數的中位數是 16.827； (C)facebook 變數的第三四分位數(Q3)是 11.94； (D)youtube 變數的第一四分位數(Q1)是 89.25
C	49 參考下圖計算各變數的遺漏值(NaN)個數結果，下列何者正確？ <pre>youtube      0 facebook     1 newspaper    0 sales        0 dtype: int64</pre> <p>選項 A: df.isnull().sum() 選項 B: df.isnan().sum() 選項 C: df.isna().sum() 選項 D: df.isnan().sum() (A)選項 D； (B)選項 B、選項 C、選項 D； (C)選項 A、選項 C；</p>

# 114 年第二次 AI 應用規劃師-中級能力鑑定【公告試題】

## 第二科：大數據處理分析與應用

考試日期：114 年 11 月 08 日 試題公告日期：114 年 11 月 20 日

答 案	題目
	(D)選項 A、選項 B、選項 C
B	<p>50 考慮資料集已經填補遺漏值，參考下圖執行結果，下列何者正確？</p> <pre>from sklearn.linear_model import LinearRegression import statsmodels.api as sm X = df[['youtube', 'facebook', 'newspaper']] y = df['sales'] reg = 空格1 print(reg.coef_) X2 = sm.add_constant(X) model_sm = 空格2 print(model_sm.summary())</pre> <p style="background-color: #f0f0f0; padding: 10px;">         OLS Regression Results          ======          Dep. Variable: sales R-squared: 0.898          Model: OLS Adj. R-squared: 0.896          Method: Least Squares F-statistic: 573.0          Date: Sat, 20 Sep 2025 Prob (F-statistic): 1.03e-96          Time: 19:37:30 Log-Likelihood: -422.21          No. Observations: 200 AIC: 852.4          Df Residuals: 196 BIC: 865.6          Df Model: 3          Covariance Type: nonrobust          ======          coef std err t P&gt; t  [0.025 0.975]          -----          const 3.5561 0.373 9.537 0.000 2.821 4.291          youtube 0.0455 0.001 32.702 0.000 0.043 0.048          facebook 0.1891 0.009 21.960 0.000 0.172 0.206          newspaper -0.0006 0.006 -0.108 0.914 -0.012 0.011       </p> <p>A : 空格 1 完整語法 reg = LinearRegression().fit(y, X)    B : 空格 1 完整語法 reg = LinearRegression().fit(X, y)    C : print(reg.coef_) 結果為包括截距項等 4 個係數值    D : 空格 2 完整語法 sm.OLS(X2, y).fit()    E : model_sm 迴歸模型的所有迴歸係數在 <math>\alpha=0.05</math> 之下具有顯著的解釋力    F : 截距項係數值為 3.5561    (A)B、C、F    (B)B、F    (C)A、C、D、F    (D)B、E</p>

《以下空白》